



香港城市大學
City University of Hong Kong

生成式图像压缩调研汇报

汇报人：朱凌玉

成员：盛锡华，朱凌玉，黄子川，文以恒

导师：王诗淇

计算机系
香港城市大学

2025.8.25

01

背景介绍

生成式图像
压缩目标


超低码率压缩画质——“更高”
适配真实复杂场景——“更强”
较低模型计算开销——“更快”



内容


图像编码压缩介绍
VQGAN图像压缩
扩散模型图像压缩
编码关键技术解析

架构



CNN/Transformer (PSNR, MS-SSIM)

演变



GAN/Diffusion (LPIPS, DISTS)

总结 新架构破固标，极低码率铸高能




香港城市大學
City University of Hong Kong

01

背景介绍

图像压缩与生成




01

背景介绍

图像压缩与生成


传统编码压缩

率失真优化 (RD)
压缩理论与方法

移动设备



视频监控



传统编码性能演变

01

背景介绍

图像压缩与生成


Text: A gray sketch on paper of a Ferrari car, full car, pencil art




图像可控生成实例

图像生成模型

扩散模型驱动的 图像可控生成



生成式基础模型




内容创作

01

背景介绍


生成式图像压缩演变



2.1 VQGAN图像压缩

➤ 研究动机

- 先前技术的局限性：单一码本的方法优先聚焦于数据集中**共同语义的聚类**，却**忽视**了对个体对象和场景的保持至关重要的**多样细节**，**不利于图像编码压缩**。




- 潜在表示分解为两个独立的元素：语义组件和细节组件，并通过不同的压缩分支进行处理。这种架构分离解决了单一代码本方法所面临的基本权衡，使每个分支能够专注于各自的领域。

2.1 VQGAN图像压缩

➤ 技术贡献

■ 与之前编码压缩网络结构差异



(1) **双分支编码结构**：双分支编码框架用于极端图像压缩。该框架将特征分解为一般语义部分和具体细节部分，能够动态适应每幅图像的内容变化，从而实现灵活的压缩

(2) **跨分支冗余**：跨分支交互结构，以消除语义和细节比特流之间的冗余，进一步提高压缩效率。

02


最新进展

2.1 VQGAN图像压缩

➤ 实验结果



香港城市大學
City University of Hong Kong



Xue N, Jia Z, Li J, et al. DLF: Extreme Image Compression with Dual-generative Latent Fusion[J]. arXiv preprint arXiv:2503.01428, 2025.

02

最新进展

2.1 VQGAN图像压缩

➤ 实验结果



香港城市大學
City University of Hong Kong

Original	MS-ILLM	PerCo	DiffEIC	DLF (Ours)
Bpp ↓ / LPIPS ↓ / DISTS ↓	0.0146 (1.05x) / 0.348 / 0.203	0.0328 (2.75x) / 0.440 / 0.204	0.0236 (1.98x) / 0.430 / 0.161	0.0119 (1.00x) / 0.241 / 0.121
Bpp ↓ / LPIPS ↓ / DISTS ↓	0.0173 (1.40x) / 0.370 / 0.216	0.0327 (2.63x) / 0.511 / 0.249	0.0267 (2.15x) / 0.423 / 0.176	0.0124 (1.00x) / 0.317 / 0.159

Xue N, Jia Z, Li J, et al. DLF: Extreme Image Compression with Dual-generative Latent Fusion[J]. arXiv preprint arXiv:2503.01428, 2025. 10


02

最新进展

2.1 去噪扩散概率模型 (DDPM)

➤ 向前扩散过程

- 向前技术：向前扩散过程是逐步向图像中加入噪声，直到完全变成随机噪声。



2.1 去噪扩散概率模型 (DDPM)

➤ 向前扩散过程

- 向前技术：向前扩散过程是逐步向图像中加入噪声，直到完全变成随机噪声。



$$\text{Define } \bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s) \quad \rightarrow \quad q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}) \quad (\text{Diffusion Kernel})$$

$$\text{For sampling: } \mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{(1 - \bar{\alpha}_t)} \epsilon \quad \text{where } \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

β_t values schedule (i.e., the noise schedule) is designed such that $\bar{\alpha}_T \rightarrow 0$ and $q(\mathbf{x}_T | \mathbf{x}_0) \approx \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I})$


2.1 去噪扩散概率模型 (DDPM)

➤ 反向扩散过程

- 反向去噪：反向去噪过程是通过学习的概率模型逐步去除噪声，从纯噪声中还原出清晰图像。

去除噪声

原始
数据



高斯
噪声


2.1 去噪扩散概率模型 (DDPM)

➤ 反向扩散过程

- 反向去噪：反向去噪过程是通过学习的概率模型逐步去除噪声，从纯噪声中还原出清晰图像。

去除噪声

原始
数据



高斯
噪声

$$\begin{aligned}
 p(\mathbf{x}_T) &= \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I}) \\
 p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) &= \mathcal{N}(\mathbf{x}_{t-1}; \underbrace{\mu_{\theta}(\mathbf{x}_t, t)}_{\text{Trainable network (U-net, Denoising Autoencoder)}}, \sigma_t^2 \mathbf{I})
 \end{aligned}
 \quad \rightarrow \quad
 p_{\theta}(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)$$

Vahdat et al., "Denoising Diffusion Models: A Generative Learning Big Bang," CVPR 2023 Tutorial.

2.2 DiffEIC扩散模型图像压缩


➤ 技术贡献

- 开发端到端框架，利用稳定扩散的强大生成能力，实现图像压缩的**率-失真-真实感**权衡。

➤ 研究动机


- 先前技术的局限性：

- (1) **低码率性能差**：传统的算法**产生严重的块效应和质量下降**。
- (2) **灵活性差**：图像被表示为压缩的潜在特征，利用潜在特征来引导扩散过程差，实质上**将解码视为一个条件生成问题**。
- (3) **条件引导差**：过度依赖生成先验而非特定输入信息，**偏离原始内容**。



2.2 DiffEIC扩散模型图像压缩


➤ 实验结果



Li Z, Zhou Y, Wei H, et al. Towards extreme image compression with latent feature guidance and diffusion prior[J].TCSVT, 2024.

2.2 DiffEIC扩散模型图像压缩

➤ 实验结果



2.3 扩散模型图像压缩处理噪声

➤ 研究动机

■ 关键见解：

(1) **均匀量化**：训练用于逆向噪声过程的扩散模型能够“去噪”量化引入的伪影，从而实现图像压缩质量提升。

(2) **负面影响扩散基压缩性能**：噪声类型差距，量化误差与扩散模型分布差异；噪声水平差距，部分噪声数据中预期和实际信噪比不匹配；离散化差距，离散数据传递给连续扩散模型。



Source

Ours

Noise Level Gap

Under-denoised

Over-denoised

Noise Type Gap


Discretization Gap

Relic L, Zhang Y, et al. Bridging the Gap between Gaussian Diffusion Models and Universal Quantization for Image Compression. CVPR 2023, 18

2.3 扩散模型图像压缩处理噪声

➤ 技术贡献

- 全面的技术框架，通过特定的设计创新来解决每个识别出的差距：



□ Original: $y_t = \sqrt{\alpha_t}y_0 + \epsilon, \quad \epsilon \sim \mathcal{N}(0, (1 - \alpha_t)\mathbf{I})$

□ Universal quantization: $\hat{y} = \lfloor y - u \rfloor_{\Delta} + u \stackrel{d}{=} y + u', \quad u, u' \sim \mathcal{U}[-\Delta/2, \Delta/2]$

➔ $\hat{y}_t = \lfloor \sqrt{\alpha_t}y - u \rfloor_{\Delta_t} + u, \quad u \sim \mathcal{U}[-\Delta_t/2, \Delta_t/2]$
 $\hat{z} = \lfloor \sqrt{\alpha_t}y - u \rfloor_{\Delta_t}, \quad \hat{y}_t = \hat{z} + u$

□ SNR: $\text{SNR}(\hat{y}_t) = \text{SNR}(y_t) \quad \forall t \in \{T, \dots, 0\}$

➔ $\Delta_t = \sqrt{12(1 - \alpha_t)}$

【全面框架】

- 将量化数据置于扩散轨迹上，从而在压缩和扩散建模之间耦合。

【量化调度】

- 通过用均匀噪声而非高斯噪声训练扩散模型来解决，。

2.3 扩散模型图像压缩处理噪声

➤ 技术贡献

- 提出了一种基于扩散的新型图像编解码器，解决产生负面影响的缺陷：i) 噪声类型缺陷，ii) 噪声水平缺陷，以及 iii) 离散化缺陷
- 建立了潜在均匀噪声扩散模型的有效性，并表明可以通过微调基础高斯扩散模型（Finetune Stable Diffusion v2.1）来有效地获得该模型

$$\hat{\mathbf{y}}_t = \lfloor \sqrt{\alpha_t} \mathbf{y}_0 - \mathbf{u} \rfloor_{\Delta_t} + \mathbf{u}, \quad \mathbf{u} \sim \mathcal{U}[-\Delta_t/2, \Delta_t/2]$$

$$\stackrel{d}{=} \sqrt{\alpha_t} \mathbf{y}_0 + \mathbf{u}$$

$$\text{Var}[\mathbf{u}] = \frac{1}{12} \left(\frac{\Delta_t}{2} - \frac{-\Delta_t}{2} \right)^2$$

$$= \frac{1}{12} \Delta_t^2$$

$$\therefore \text{SNR}(\hat{\mathbf{y}}_t) = \frac{\mathbb{E}[(\sqrt{\alpha_t} \mathbf{y}_0)^2]}{\frac{1}{12} \Delta_t^2}$$

$$\text{SNR}(\hat{\mathbf{y}}_t) = \text{SNR}(\mathbf{y}_t)$$

$$\frac{\mathbb{E}[(\sqrt{\alpha_t} \mathbf{y}_0)^2]}{\frac{1}{12} \Delta_t^2} = \frac{\mathbb{E}[(\sqrt{\alpha_t} \mathbf{y}_0)^2]}{1 - \alpha_t}$$

$$\frac{1}{12} \Delta_t^2 = 1 - \alpha_t$$

$$\Delta_t = \sqrt{12(1 - \alpha_t)}.$$

Relic L, Zhang Y, et al. Bridging the Gap between Gaussian Diffusion Models and Universal Quantization for Image Compression. CVPR 2024

02


最新进展



香港城市大學
City University of Hong Kong

2.3 扩散模型图像压缩处理噪声

➤ 实验结果



Relic L, Zhang Y, et al. Bridging the Gap between Gaussian Diffusion Models and Universal Quantization for Image Compression. CVPR 2024

2.4 StableCodec扩散模型图像压缩

➤ 研究动机

- 先前技术的局限性：先前的扩散图像压缩网络DiffEiC基于ControlNet引导生成高质量图像，需要多步去噪（50步），运算时间显著（11.1s），不利于实际部署。




- 一步扩散模型：StableCodec 方法通过利用大型预训练的文本到图像扩散模型的生成先验，特别是针对一步扩散处理，旨在弥合扩散模型高质量重建能力与实际压缩应用需求之间的差距。

2.4 StableCodec扩散模型图像压缩

➤ 技术贡献

■ 对抗扩散图像压缩，用于生成式图像压缩的单步扩散网络方法





(1) **一步扩散模型结构**: 结合了一步扩散和深度压缩潜在编解码器，实现超低比特率压缩，同时具备高真实感、高保真度和卓越的编码效率

(2) **双分支编码和解码**: 双分支编码结构，以提高重建保真度。引入了一对辅助编码器和解码器，用于语义增强和结构分配。

2.4 StableCodec扩散模型图像压缩

➤ 技术贡献


■ 双编码解码结构可视化分析



(a) Latents from different decoders, trained w. or w/o $\mathcal{D}_{Aux}$



2.4 StableCodec扩散模型图像压缩

➤ 实验结果



2.4 StableCodec扩散模型图像压缩


➤ 实验结果

Original	ELIC	MS-ILLM	PerCo	DiffEIC	EGIC	TACO	StableCodec (Ours)
							
bpp / DISTIS ↓	0.028 bpp / 0.285	0.036 bpp / 0.103	0.032 bpp / 0.130	0.035 bpp / 0.107	0.028 bpp / 0.136	0.038 bpp / 0.121	0.027 bpp / 0.082
							
bpp / DISTIS ↓	0.031 bpp / 0.320	0.039 bpp / 0.147	0.032 bpp / 0.155	0.043 bpp / 0.127	0.029 bpp / 0.149	0.045 bpp / 0.129	0.028 bpp / 0.109
							
bpp / DISTIS ↓	0.042 bpp / 0.310	0.050 bpp / 0.161	0.033 bpp / 0.188	0.046 bpp / 0.144	0.037 bpp / 0.156	0.056 bpp / 0.170	0.032 bpp / 0.107

2.5 扩散模型图像压缩标准提案

➤ 技术贡献

■ 一种新型自动化衡量图像解码保真度和感知的方法



■ CorrDiff 的动机:


(1) **扩散模型**它们倾向于重建出更丰富的视觉**细节**，但对原始图像的保真度较低。这一局限性源于逐步添加和去除噪声的过程。

(2) 虽然增强了细节重建能力，但对**失真度量却不友好**。

2.5 扩散模型图像压缩标准提案

➤ 技术贡献

■ 一种新型自动化衡量图像解码保真度和感知的方法




■ CorrDiff 的核心创新:

(1) 这一设计的优雅效率源于其能够简单地**发送这些线性系数**，这些系数仅需**少量比特**作为特权信息，帮助解码器校正采样过程，从而使重建结果获得更好的视觉质量。

(2) 这种方法有效地弥合了扩散模型的生成能力与图像压缩的精度要求之间的差距，通过针对性地校正采样过程，而**不会显著增加比特率开销**。

2.5 扩散模型图像压缩标准提案

➤ 实验结果




Y. Ma, W. Yang, and J. Liu, "Correcting diffusion-based perceptual image compression with privileged end-to-end decoder", ICML, 2024.

2.6 关键技术理解-文本作用

➤ 研究动机


- 以 LMM 驱动的语义图像压缩的核心动机源于现有方法在超低比特率下的局限性。传统的学习压缩方法在极低比特率下会遭遇模糊和严重的语义丧失。这为压缩任务提供了新的见解：
- (1) **语义级压缩可以通过在更高效的表示空间中操作，超越传统的像素级编解码器。**
- (2) **帮助编解码器理解真正重要的内容——本质上是确定什么是最值得压缩的。**



"The image features a group of motorcyclists lined up on a dirt track. There are five motorcycles in total, with each rider wearing a helmet. The riders are standing next to their bikes, showcasing their skills and preparing for the race. The scene captures the excitement and anticipation of the event, as the riders and their motorcycles are ready to compete."

2.6 关键技术理解-文本作用


➤ 实验结果



2.6 关键技术理解-文本作用

➤ 研究动机

- 人类可以轻松地将复杂的视觉场景转化为简单的词语，利用其对内容的高级理解，但传统和学习型图像压缩编解码器并未充分利用视觉内容的语义意义。
- 这引出了一个关键问题：如何有效地传递文本级语义依赖，以帮助图像压缩




- 创建深度图像压缩方法，**使用文本作为额外信息**，实现更好的比率-感知-失真权衡。
- 通过自引入框架，**将文本语义直接嵌入到学习压缩管道的潜在层面**，避免了单独的文本-图像路径，并消除了对外部解码器信息的依赖。

2.6 关键技术理解-文本作用

➤ 技术贡献

- 对齐模块：给定输入图像，语义分支首先通过**语义图像到文本编码器**（BLIP）将其转换为文本描述。然后，这一**文本输出到张量编码器**（BERT）成一个固定维度的紧凑语义特征。
- 预训练模型：通过预训练的文本模型丰富潜在表示，融入了上下文语义信息




02

最新进展


2.6 关键技术理解-文本作用

➤ 实验结果

消融实验



性能对比




香港城市大學
City University of Hong Kong

02

最新进展

2.7 最新算法细节对比


➤ 技术对比



- ❑ 2 RTX 3090 GPU 训练
- ❑ 双分支编码策略
- ❑ 损失优化 MSE, LPIPS (VGG), CLIPQA and GAN (multi-stage)
- ❑ 卷积神经网络模块
- ❑ 编解码时间: **编码 0.159, 解码 0.326 (3090)**




香港城市大學
City University of Hong Kong




- ❑ 4 A100 GPU 训练
- ❑ 双分支编码策略
- ❑ 损失优化 MSE, LPIPS, Codebook and GAN (multi-stage)
- ❑ Transformer Block
- ❑ 编解码时间: **编码 0.178, 解码 0.252 (A100)**

2.8 扩散模型图像压缩优势来源

➤ 可借鉴内容



- **核心技术**: StableCodec 利用预训练文本到图像扩散模型的生成先验，特别是 SD-Turbo，实现实时图像合成
- **增强重建保真度**: 引入双分支编码结构，配备辅助编码器和解码器
- **优化**: 联合优化比特率和像素级约束。




- **潜在表示分解**: 方法将潜在表示分解为语义和细节元素，通过两个分支进行压缩。
- **语义和细节分支**: 语义分支聚类高级信息，细节分支编码关键细节，从而提高重建保真度。
- **跨分支交互机制**: 利用多个注意力层共同处理特征，优化比特分配并减少冗余。

3.1 总结

➤ 任务背景

- 问题定义：超低码率图像压缩（Ultra-Low Bitrate Image Compression）旨在以极低的比特率将图像数据压缩至最小，同时保持图像的视觉质量，以满足带宽限制和存储需求。
- 关键挑战：如何设计生成式压缩算法在超低码率场景的下的画质表现和效率？



总结概括 用新工破固标，极低码率铸高能



香港城市大學
City University of Hong Kong

感谢大家!

Thank You!