

超低码率生成式图像压缩技术报告

目录

一、	生成式图像压缩背景与介绍	3
二、	基于向量量化生成对抗网络（VQGAN）的图像压缩	5
2.1	基于 VQGAN 压缩方法的基本原理	5
2.2	基于 VQGAN 压缩方法的相关研究	6
2.3	基于 VQGAN 压缩方法关键技术剖析	7
2.3.1	双分支 Encoder-Decoder 结构的必要性	7
2.3.2	码本的设计与优化	8
2.3.3	损失函数的设计	10
三、	基于扩散模型（DIFFUSION MODEL）的图像压缩	12
3.1	图像压缩的扩散过程原理	12
3.2	基于扩散模型图像压缩的相关研究	13
3.3	基于扩散模型图像压缩方法关键技术剖析	16
3.3.1	双分支范式分析	16
3.3.2	文本信息在生成图像中的作用	17
3.3.3	GAN 与一步扩散模型区别与联系	21
3.3.4	损失函数与优化	24
3.3.5	量化和噪声处理	25
3.3.6	基于残差的生成式扩散模型图像压缩分析	26
四、	基准测试与性能指标的模型复杂度分析	28
4.1	基于 VQGAN 图像压缩的性能与复杂度分析	28
4.2	基于扩散模型图像压缩的性能与复杂度分析	29
五、	技术迁移至低复杂度的 AI 编码器思路设计	32
5.1	损失函数的影响	32
5.2	先验的影响	33
5.3	简化 VQGAN 图像压缩的技术路线	34
5.4	简化扩散模型的图像压缩技术路线	36
5.4.1	单步扩散图像压缩	36
5.4.2	单分支编码双分支解码架构设计	38
5.4.3	LoRA 微调训练	38
六、	未来方向探索	39

6.1	基于扩散的图像初步压缩方案.....	39
6.2	标准化	41
6.3	扩散图像压缩编码器深度分析.....	43
6.3.1	扩散图像压缩范式优势来源.....	44
6.3.2	扩散模型噪声的作用.....	46
6.3.3	扩散模型去噪多步的合理性.....	47
6.3.4	双分支策略及残差策略分析.....	49
6.3.5	蒸馏方式对提升主观性能	50
七、	参考文献	51

一、生成式图像压缩背景与介绍

生成图像压缩是一个新兴领域，基本上与传统压缩技术（如 JPEG 或 PNG）不同。生成图像压缩不仅在技术上与传统方法存在显著差异，而且在实际应用中展现出巨大的潜力。通过利用深度学习模型，生成式图像压缩能够更有效地捕捉图像中的重要特征和结构，这使得即使在高压缩比下，也能保持较好的视觉质量。传统方法侧重于通过变换、量化和熵编码直接编码像素信息，而生成式压缩则利用深度生成模型的强大能力，实现更高的压缩率。这些模型学习捕捉图像的潜在概率分布，使其能够存储紧凑的潜在表示。

生成式压缩的核心原理是将图像编码为压缩的潜在空间，然后使用解码器重建原始图像。这种方法可以显著减小文件大小，因为模型只需存储生成图像所必需的信息，而不是每个像素。常见的生成式模型种生成式架构，包括变分自编码器（VAEs）、生成对抗网络（GANs）以及最近的扩散模型（Diffusion Model）。

基于变分自编码器（Variational Autoencoder, VAE）的图像压缩方法利用 VAE 在学习数据分布方面的能力，将高维图像映射到一个结构化的潜在空间，并从中学习到能够有效重建图像的紧凑表示。在这一框架中，编码器负责将输入图像压缩为一组潜在变量的分布参数（均值和方差），随后通过重参数化技巧从该分布中采样，生成潜在表示向量；解码器则从这一潜在向量重建出原始图像的近似版本。为了进一步实现压缩，通常会对潜在变量进行量化，并采用熵编码方法（如算术编码）对其进行

编码，从而达到减少比特率的目的。然而，基于 VAE 的图像压缩方法也存在一些明显的劣势。首先，经典 VAE 常出现图像模糊的问题，这是因为其解码器优化的重建目标往往趋向于像素均值，从而损失细节信息。其次，VAE 压缩方法在高比特率条件下的性能往往不如基于变换编码的深度压缩方法，其推理速度受限于复杂的熵建模和采样过程。此外，由于 VAE 是一个概率模型，其推理过程中涉及采样操作，这在部署时可能带来不可预期的随机性，影响压缩一致性与稳定性。因此，尽管基于 VAE 的图像压缩在生成建模与端到端优化方面具有一定优势，但其在重建质量、解码速度与工业可用性方面仍面临挑战。

基于生成对抗网络（GAN）的生成图像压缩作为一种新兴的方法，根本改变了我们对压缩的理解。它通过使用生成对抗网络学习图像的紧凑表示，而不是存储像素值或变换系数。这些方法学习将图像编码为潜在空间，然后使用训练好的生成器从这些压缩表示中重建高质量图像。关键在于，GAN 能够生成逼真的图像内容，尽管可能与原始图像不完全匹配，但在视觉上对人类观察者来说是可信的。这种生成方法允许在极低比特率下保持感知质量，特别适用于对视觉保真度要求高于像素完美重建的应用。随着 GAN 在图像生成任务中的成功，该领域获得了显著的动力，研究人员认识到相同的对抗训练原则可以应用于压缩，通过训练生成器从紧凑代码中重建图像。

基于扩散模型的压缩特别受到关注，因为它在从非常紧凑的表示中生成高质量图像方面表现出色。优化基于扩散的压缩模型的一个重大挑战在于平衡不同的目标。存在着扩散过程的随机特性与比特率要求所施

加的约束之间的固有冲突。这种根本性的冲突源于生成模型优先考虑在没有比特率监督的情况下生成高质量内容，而压缩技术旨在遵循香农信息理论的前提下，在有限比特率内有效表示和重建原始图像。这些模型通过在训练过程中逐渐向图像添加噪声，然后学习在生成过程中逆转这一过程，从而实现图像的生成。这为图像压缩提供了强大的框架，因为它能够有效捕捉复杂的图像特征和纹理，同时保持小的潜在表示。

本报告旨在调研最近的生成式图像压缩技术方案，降低存储需求，在特定极端码率场景，例如卫星通信应用中提高图像质量，为下个阶段提供技术指引。

二、基于向量量化生成对抗网络（VQGAN）的图像压缩

2.1 基于 VQGAN 压缩方法的基本原理

VQGAN（Vector Quantized Generative Adversarial Network）^[1]是一种结合向量量化（VQ）与生成对抗网络（GAN）的生成模型，其核心思想是通过分层学习离散隐表示来提升图像生成的多样性和质量。VQGAN 通常由两个核心组件构成：1) 基于 Transformer 或 CNN 的编码器-向量量化-解码器结构，用于将图像映射到离散隐空间并重建；2) 对抗性训练机制，通过判别器提升生成图像的视觉真实性。

由于离散隐表示（Discrete Latent Representation）相比原始图像数据显著降低了比特率，因此 VQGAN 应用于图像压缩任务时能够兼顾离散建模能力、重构质量和感知优化等多方面需求，相比传统方法在低比特

率下能保持更优的视觉质量。基于 VQGAN 的图像压缩性能主要与码本大小相关：码本容量越大，重建质量越高，但需要更多比特存储离散表示的索引，从而降低压缩效率；码本容量越小，压缩效率越高，但可能导致图像细节丢失，重建质量下降。

2.2 基于 VQGAN 压缩方法的相关研究

目前基于 VQGAN 的压缩方法主要围绕扩大码本规模和补充细节语义等方面展开研究。然而，由于码本训练过程复杂且计算成本较高^[8]，大型码本在实际部署中存在限制。因此，当前更主流的优化方向是在现有 VQGAN 框架的基础上增强语义表达能力，主要分为两类：1) 优化隐表示（例如 ALIT^[2]），在 VQGAN 内部改进离散隐空间的建模能力；2) 引入外部语义信息（例如 DLF^[3]），通过额外网络或数据增强补充细节。

优化隐表示的方法如 ALIT，根据信息熵和上下文动态分配计算资源，为不同的输入图像分配自适应性不定长 Token，从而在提升高密度信息对应的视觉质量的同时降低低密度信息的码率，克服了传统压缩方法（如 JPEG）在低码率下的块效应问题，使边缘和纹理的重建更加自然。

引入外部信息的方法通常采用多分支（Multi-branch）网络结构，可显著提升编码网络的性能、表达能力与压缩效率。这类方法在极低比特率压缩、细节保持和架构灵活性方面表现突出，但也面临训练难度大、计算成本高、泛化性受限和依赖先验知识等挑战。

2.3 基于 VQGAN 压缩方法关键技术剖析

2.3.1 双分支 Encoder-Decoder 结构的必要性

多分支网络结构，尤其是双分支编码器（Dual-branch Encoder），逐渐成为近年来 VQGAN-based 压缩方法提升性能的主要方向。代表性工作如 DLF 通过语义分支和细节分支分别提取图像的核心语义和背景细节，在极低的码率下仍能保持较好的画面结构；而 MRIDC^[4]则采用多分辨率分支协同提取不同尺度的特征信息，以提高低码率下的重建能力。




图 1 DLF 模型结构示意图

双分支 Encoder 的核心作用在于实现不同维度的特征分离，使得不同类型的信息可以在编码过程中独立建模并压缩，从而有效降低了特征间的干扰和冗余，提高了量化效率与重建质量。此外，双分支结构还能增强模型对复杂内容的适应性与可控性，便于在结构/纹理、高频/低频、语义/细节等维度上进行粒度调节。

与传统的单分支结构相比，双分支设计在重建质量、感知一致性与扩展性上具有明显优势。但这种结构也带来了更多的挑战，主要体现在网络复杂度、训练难度、推理效率与融合机制四个方面。

首先，双分支结构需要同时设计两套相对独立但功能互补的编码路径（如结构分支与纹理分支），不仅加重了网络参数数量，还要求分支间具备良好的协同能力，显著增加了模型的架构复杂性。这种结构的复杂度通常带来更高的计算开销和存储需求，对设备资源有限的实际部署场景不够友好。

第二，双分支设计还会影响推理效率与时延。由于存在两条并行路径，推理阶段的前向传播时间相比单分支显著增加，尤其是在高分辨率图像压缩任务中。同时，每个分支在解码端往往需要设计对应的解码模块，并在特征层或图像层进行融合，进一步拖慢解码速度，限制其实时应用能力。

最后，双分支结构对特征融合策略依赖性强。两条分支在训练过程中分别编码不同类型的语义或视觉特征，融合过早可能导致特征混淆，融合过晚又可能使局部细节或结构信息无法充分交互。如果融合模块设计不合理，不仅无法充分发挥双分支结构的优势，反而可能破坏特征表达的一致性与完整性，导致图像重建质量下降。

尽管双分支 Encoder 为 VQGAN 图像压缩提供了更强的表征能力与感知性能，其带来的训练难度、推理开销、融合机制设计成本以及平台适配性问题仍不可忽视。在实际部署或大规模推广时，如何在分支之间保持结构简洁与表征独立性的平衡，仍是该方向亟待解决的核心挑战。

2.3.2 码本的设计与优化

在基于 VQGAN 的图像压缩方法中，码本（Codebook）的设计是影

响压缩率与重建质量的关键因素。为了在极低比特率下实现高质量图像重建，近期的优化与探索主要围绕码本的容量控制、语义分布、利用效率以及可扩展性等方面。

首先，从压缩率的角度来看，码本大小决定了单个索引所需的比特数。较大的码本具备更强的表示能力，但会带来更高的索引存储开销，因此在极低码率场景下，往往需要通过结构设计和算法优化，在保证表达力的前提下压缩索引信息。例如，Finetuned-GAN^[7]通过聚类缩减与Transformer 预测机制，压缩码本的同时保留其重建能力，有效提升在低于 0.04 bpp 下的感知质量。而 VQGAN-LC^[8]则将码本规模扩展至 100,000，并通过正则化训练手段实现 99% 的码本利用率，从而兼顾表达能力与紧凑性。

另一方面，为了确保压缩后的图像能够被高质量地重建，码本的设计也需充分考虑语义表达与结构分布。合理的码字分布应能在潜在空间中形成具有语义聚类特性的局部区域，使得语义或视觉相近的图像片段能够被映射到相邻的编码区域，从而降低 decoder 的重建负担。为此，研究者们提出了多种提升语义一致性的策略，例如 DLF^[3]通过语义分支和细节分支的双生成流分离潜在信息，使得压缩后的语义保持更清晰，结构细节更丰富；SQ-GAN^[9]则通过语义掩模机制仅对图像中关键语义区域进行向量量化，进一步提高了压缩效率和语义可控性。

此外，在 DiffPC^[10]中，研究者结合语义引导的上下文信息与扩散模型的恢复能力，通过对码字隐变量进行语义增强，有效降低了因压缩导

致的细节缺失问题；Control-GIC^[11]提出动态粒度控制机制，结合图像复杂度区域选择合适的码字编码策略，实现单模型下多比特率自适应能力；Finetuned-GAN 中结合 Transformer 预测机制恢复丢失索引，缓解因码本压缩带来的细节损失，进一步弥补低码率带来的细节退化问题。

高效的码本设计需要在紧凑性与表达力之间取得动态平衡：在低比特率场景中强调索引压缩与码本利用，而在高保真重建场景中则更重视语义结构与多分支编码的融合能力。随着生成模型与语义控制能力的不断增强，未来的 VQ 码本设计也将进一步朝着可控性、自适应粒度和任务兼容性方向发展。

2.3.3 损失函数的设计

通过多样的结构设计 with 损失函数组合，不断提升压缩图像的结构还原能力与感知质量，近期基于 VQGAN 的图像压缩方法在极低比特率场景中展现出显著优势。基于单分支/多分支的网络结构差异，它们在编码路径设计、损失函数构成及任务适应性等方面展现出不同的策略与权衡。

单分支结构通常采用统一的编码-解码通路，不涉及结构或语义信息的显式划分。在这些方法中，损失函数设计主要围绕重建损失、VQ 损失、感知损失和部分对抗损失展开。重建损失（Reconstruction Loss）通过 L1/L2 范数确保重建图像与原图的像素级一致性，是压缩任务的基础，几乎所有方法均依赖其保证训练稳定性。VQ 损失通常由 Commitment Loss 与 Embedding Loss 组成，用于维持编码器输出与码本向量之间的一致性，防止码本坍缩或使用效率低下。感知损失（Perceptual Loss）则通过预训

练 VGG 网络的特征比对，引导模型生成更符合人类视觉偏好的结果，从而提升图像在感知层面的细节质量，尤其在低比特率下至关重要。此外，对抗损失（Adversarial Loss）的引入进一步增强了高频细节的真实感，例如 StableCodec^[5]和 DLF 等工作中采用的 PatchGAN 判别器在草地、毛发等复杂纹理的还原上有效提升了图像的视觉自然度，但其不稳定性使其更多作为辅助损失存在。

相较而言，多分支结构通过在编码或解码阶段显式划分出多个信息通路，通常以结构信息与纹理信息或语义信息与细节信息分别建模，从而在极端压缩率下仍能保留图像语义一致性与感知质量。以 DLF 为例，其通过语义分支与细节分支分别生成结构主干与纹理增强图，再进行融合重构，在 0.01 bpp 以下仍能维持极高的 LPIPS 表现。由于分支结构复杂、功能差异化显著，这类方法在损失函数设计上更为细致与任务导向，除了保留基础的重建损失和 VQ 损失外，常引入语义一致性损失、结构掩模损失（如语义引导的区域感知损失）以及 DISTS 等融合结构与感知的指标函数。此外，对抗损失在多分支模型中发挥更大作用，尤其在细节重建支路中，用以恢复局部纹理与边缘的真实感。

损失函数的配置上，重建损失与 VQ 损失是所有 VQGAN-based 方法的基础，而感知损失、对抗损失和结构语义引导类损失则是感知型压缩方法不可或缺模块。未来发展中，预计将进一步朝向统一多模态表示、语义可控重建以及扩散与量化融合等方向推进，尤其在模型压缩与分支融合机制上仍有巨大优化空间。

三、基于扩散模型（Diffusion Model）的图像压缩

3.1 图像压缩的扩散过程原理

扩散模型作为一种强大的生成模型，通过逐步的去噪过程学习数据分布，从高斯噪声开始，逐渐逼近实际数据分布。这些模型在各种计算机视觉任务中表现出色，包括图像生成、超分辨率、图像修复和去模糊。




图 2 扩散过程示意图

正向扩散过程: 给定一个从真实数据分布中采样的数据点 $x_0 \sim q(x)$, 我们定义一个正向扩散过程, 在这个过程中, 我们在 T 步中向样本添加少量高斯噪声, 生成一系列噪声样本 $x_1, \dots, x_T$ 。步长由方差调度 $\{\beta_t \in (0,1)\}_{t=1}^T$, 具体公式如下所示:

$$q(x_t|x_{t-1}) = N(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I) q(x_{1:T}|x_0) = \prod_{t=1}^T q(x_t|x_{t-1})$$

随着步骤 t 的增大, 数据样本 x_0 逐渐失去其可区分的特征。最终, 当 T 趋近于无穷大时, 最终得到一个各向同性的高斯分布。

反向扩散过程: 如果我们能够反转上述过程, 并从 $q(x_{t-1}|x_t)$ 中采样, 我们将能够从高斯噪声输入重建真实样本, 即 $x_T \sim (0, I)$ 。请注意, 如果

β_t 足够小, $q(x_{t-1}|x_t)$ 也将是高斯分布。不幸的是, 我们无法轻易估计, 因为它需要使用整个数据集, 因此我们需要学习一个模型 p_θ 来近似这些条件概率, 以便进行反向扩散过程。具体公式如下所示,

$$\begin{aligned} p_\theta(x_{0:T}) &= p_{(x_T)} \sum_{t=1}^T p_\theta(x_{t-1}|x_t) p_\theta(x_{t-1}|x_t) \\ &= N\left(x_{t-1}; \mu_\theta(x_t, t), \sum_\theta(x_t, t)\right) \end{aligned}$$

扩散模型的训练目标是最小化前向扩散和逆向扩散之间的 KL 散度。具体来说, 训练目标可以表示为:

$$L = E_{x_0, \epsilon, t} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$$

其中, ϵ 是前向扩散过程中添加的噪声, ϵ_θ 是神经网络预测的噪声。

3.2 基于扩散模型图像压缩的相关研究

基于扩散的压缩方法的基础性研究遵循变换编码范式, 在该范式中, 图像被映射到潜在空间中进行熵编码, 然后再重建回数据空间^[12]。这项开创性工作引入了一项关键创新: 用条件扩散模型替代 VAE 基础神经压缩中使用的确定性解码器。该方法引入了一个额外的内容潜变量, 以条件化反向扩散过程并存储重要的图像信息, 而在解码过程中合成的纹理变量则用于表征细节。在此基础上, 出现了多种变体。DIRAC^[13]编解码器(扩散基础残差增强编解码器)在测试时实现了平滑的速率-失真-感知权衡, 同时在性能上与基于 GAN 的方法相当。为了解决扩散基础重建中的稳定性问题, 提出了一些一致性引导架构, 以约束扩散过程, 从而提

高重建质量。后面工作集中在架构的改进上，扩散变换器基础的解码器使用 Swin Transformer 变换器实现，以降低模型复杂性，同时保持生成能力。这些方法通常结合多尺度特征融合模块，以提升解码器的有用特征，从而改善重建质量^[14]。

基础扩散模型的使用标志着一个重要的转变，即从训练专门的压缩模型转向利用现有的大规模预训练模型。这种方法通过利用已在海量数据集上训练的模型，提供了显著的优势，使其适用于任何类型的图像，而无需进一步调整。关键的见解是，这些基础模型具备强大的生成先验，可以在重建过程中合成高频细节，从而使更多的比特分配给低频信息。在这个方向中，涌现出了一些显著的方法。PerCo^[15]通过对矢量量化的图像表示和全局图像描述进行条件化，达到了极低的比特率的出色重建质量。其他方法则专注于语义保留，通过将图像编码为低分辨率的分割图和颜色引导，实现了在保持视觉质量的同时达到极高的压缩比^[16]。最近的工作引入了端到端框架，这些框架将压缩 VAE 与固定的预训练扩散模型结合在一起。DiffEIC^[17]使用轻量级控制模块注入内容信息，同时保持稳定的扩散模型不变，以维持其生成能力。类似地，Text + Sketch^[18]使用文本提示和压缩草图与 ControlNet 结合的方法也在生成高感知质量的重建方面取得了成功。

本报告中更加关注于极低比特率范围（通常定义为低于 0.03 bpp）提出了独特的挑战，而扩散模型特别适合应对这些挑战。在这些比特率下，传统压缩方法无法保持视觉质量，因此扩散模型的生成方法自然适合在严格的信息约束下合成真实感纹理^[19]。在这一极端压缩场景中，出现了

一些开创性的方法。第一种基于扩散的极低比特率压缩方法利用现有的文本到图像模型，而无需专门训练，使其适用于任何类型的图像。在此基础上，研究人员开发了框架，用低分辨率的分割图和颜色引导替代保真度标准，以实现极高的压缩比，同时保持高视觉质量^[20]。尽管取得了这些进展，极低比特率方法仍面临固有的限制。尽管它们在与人类主观感知相符的感知指标（如 LPIPS 和 FID）中表现出色，但在像素级指标（如 PSNR 和 SSIM）上表现不如传统编解码器。此外，扩散模型在极低比特率下仍可能生成无关内容，导致重建保真度不理想。最近的发展引入了残差引导的方法，将残差信号纳入语义检索和基于扩散的生成过程中，像 ResULIC^[21]等方法在保持重建质量的同时提高了压缩效率。

扩散模型固有的迭代采样过程创造了巨大的计算开销，限制了基于扩散的压缩方法的实际应用。大多数现有的基于扩散的压缩方法需要数十或数百次去噪步骤进行重建，导致解码过程计算成本高昂，限制了其在现实世界中的适用性。为了解决这些效率挑战，研究人员开发了 zero-shot 方法，利用预训练的扩散模型而无需额外训练。后验采样基础的压缩（PSC^[22]）在这方面代表了一项显著的进展，使用预训练的扩散模型作为唯一的神经网络组件，并使得使用多种公开可用的模型成为可能。该方法表明，即使在基本量化和熵编码的情况下，也能在速率、失真和感知质量方面达到与现有训练基础方法相当的性能。最显著的效率突破来自于一步扩散方法。OneDC^[23]提出了一种框架，挑战了多步骤采样对于解码的必要性假设，提出在给定压缩潜在表示的情况下，精心设计的一步替代方法可能足够。该方法将潜在压缩模块与一步扩散生成器集成，

其中前者将图像编码为紧凑的潜在表示，而后者则根据这些潜在表示合成高频细节。这些效率改进带来的性能提升显著。OneDC 在一步生成的情况下实现了最先进的感知质量，与先前的多步骤基于扩散的编解码器相比，提供了超过 40% 的比特率降低和 20 倍的解码速度提升。这些进展建立在最近在一步扩散蒸馏方法方面的进展之上，这些方法在加速推理的同时保持图像质量方面展现出良好的前景。

基于扩散的压缩的关键优势在于其在极低比特率下生成感知上逼真的重构图像的能力，而传统编解码器在这种条件下通常会产生严重退化的图像。通过利用扩散模型学习到的先验，这些系统能够幻觉出在压缩过程中丢失的纹理细节，从而生成在视觉上更具吸引力的重构，与人类感知的匹配度高于那些像素准确但模糊的传统方法。



3.3 基于扩散模型图像压缩方法关键技术剖析

3.3.1 双分支范式分析

双分支架构代表了相较于早期的基于扩散的压缩方法的重大进展，这些传统方法通常从纯噪声开始。早期的方法如 Yang 等人提出的条件扩散压缩^[24]将扩散模型作为图像压缩的解码器引入，而后续方法如 Kuang 等人提出的一致性引导扩散模型^[25]则将端到端压缩与基于扩散的后处理网络结合，并增加了一致性引导特征分支，以约束扩散过程中的偏差。

最近的工作如 StableCodec^[5]采用的双分支实现进一步增强了这一架构，结合了专门设计的辅助编码器-解码器对，以提高重建的保真度。这一结构解决了基于扩散的方法的基本局限性，尽管使用了像矢量量化空

间特征和全局文本描述等引导技术，但在极低比特率下仍常常生成不相关的内容。双分支框架有效地将残差扩散的效率与稳定扩散模型的强大生成能力相结合，提升了保真度，同时在保持竞争力的真实感的同时，解码速度显著快于传统的基于扩散的方法。



StableCodec 的重建质量在很大程度上依赖于去噪 Unet 的条件设置。

由于在训练和推理过程中使用的是固定的提示，因此一次去噪过程主要由 g_s 生成的 l_t 指导。这对 g_s 能力要求很高，导致去噪指导效果不佳。为了解决 g_s 的解码负担，为此作者引入了一个辅助解码器 D_{aux} ，从 $\hat{y}$ 中执行额外的解码分支，绕过 Unet。这个设计基于观察到极度压缩的比特流主要包含图像的基本结构。直接从比特流中分配和解码这些组成部分，使得 g_s 能够专注于生成真实细节的指导。图中比较了使用和不使用 D_{aux} 训练的 StableCodec，结果显示 g_s 现在提供了更好的高频指导。在没有 D_{aux} 的情况下训练时， g_s 成所有类型的信息，因为它是唯一的解码分支。而在使用 D_{aux} 训练时，结构信息通过 D_{aux} 进行处理，同时 g_s 潜在空间中的能量显著减少。与此同时，生成了更多语义对齐的细节。

3.3.2 文本信息在生成图像中的作用

对于自然图像，更一般的方法采用文本反转技术，以学习最佳文本嵌入来指导图像重建。这种方法寻找一个文本嵌入，作为从随机噪声生成图像的最佳条件输入，通过迭代学习过程实现，随后将该嵌入量化并压缩以便存储。这种方法的优势在于文本嵌入具有固定的维度，与图像大小无关，使得压缩比特率依赖于原始图像的尺寸，对较大图像更为高效^[26]。

多个不同的框架应运而生，Text+sketch^[18]利用文本条件化进行基于扩散的图像压缩，各自提供不同的方法来平衡压缩效率与重建质量。基础方法涉及使用完全预训练的文本到图像模型，直接将文本作为压缩表示传输，用作条件输入，同时利用空间条件作为辅助信息。这与早期的

基于扩散的神经压缩器不同，后者传输的是量化嵌入而非可解释的文本表示。Text+sketch 使用文本提示作为主要条件信号，PICS 在文本旁边加入了草图图像，以提供空间约束，从而精确控制物体的形状和位置。在此基础上，更复杂的框架用快速前馈图像字幕替代了计算成本高昂的提示反转，并增强了使用学习的向量量化图像特征的二进制轮廓图。

专门针对屏幕内容的框架在多个架构层次上集成了文本条件化^[27]。这些系统实现了使用文本内容提示的领域级微调、使用压缩的图像和文本输入的适配器级控制，以及增强解码的实例级指导。从图像中提取和编码文本信息以用于基于扩散的压缩涉及几种不同的方法，每种方法都针对特定类型的内容和压缩需求。对于包含大量文本元素的屏幕内容图像，基于 OCR 的提取提供了一种直接捕获语义信息的方法。系统利用 Tesseract OCR 引擎提取文本内容和空间坐标，包括每个单词的左上角位置和高度，提取的文本使用专门的压缩算法进行无损压缩，而坐标则采用指数-哥伦布编码。提取的文本信息与扩散模型的集成在多个层面上进行，包括使用文本内容提示的领域级微调、使用压缩的图像和文本输入的适配器级控制，以及增强解码的实例级指导。文本条件通常被转换为表示文本内容和空间位置的字形图像，使得扩散模型能够理解文本的存在及其在重建过程中应当被放置的位置。

尽管文本条件化扩散压缩取得了有希望的进展，但仍然存在几项重大挑战限制了这些系统的实际有效性。最根本的限制在于文本提示本身的表征约束。虽然文本能够有效传达高层语义信息，但确保准确重现图像的构图和结构仍然具有挑战性，尤其对于那些无法通过自然语言充分

描述的复杂视觉内容。一个关键的技术挑战来自于特征提取过程对成对图像-文本数据的依赖。扩散模型对图像的视觉表示本质上依赖于其配对的标题，并且当在预训练期间有成对的图像-文本数据时，可以正确提取。然而，当尝试提取没有配对标题的图像的视觉表示时，这就变得问题重重，这正是压缩应用的常见使用场景。在极低比特率下，扩散模型在保持重建保真度方面面临显著挑战。尽管有各种引导技术，这些模型在极低比特率下仍然经常生成无关内容，导致重建质量不佳。这一问题在压缩方法优先聚焦于数据集中的常见语义而忽略个体物体的多样细节时尤为严重，尤其在低比特率情况下，导致保真度受到损害。这些限制促使研究人员探索超越简单文本提示的替代条件机制。对这些挑战的认识促成了超先验的开发，作为语义信号，克服文本提示的表征局限，同时保持对一步扩散解码任务至关重要的语义指导。

使用官方代码在 Murai 等人的工作^[28]上进行实验，评估文本信息的影响。如图 3 所示，“ImageTextCoding no text”变体未利用 LLaVa 生成的图像描述，而“ImageTextCoding”则包含了该图像描述。文本信息约为 0.007 bpp，总字数少于 500 个。我们观察到，当引入文本信息时，性能显著下降。




图 3 消融实验-是否包含图像描述

3.3.3 GAN 与一步扩散模型区别与联系

生成对抗网络（GANs）由两个相互竞争的神经网络组成：生成器（Generator），负责从随机噪声中生成新样本；鉴别器（Discriminator），负责区分真实数据和生成的数据。生成器的目标是通过产生越来越逼真的样本来欺骗鉴别器，而鉴别器则努力提高识别假数据的能力。这种对抗训练过程使 GAN 能够在不需要显式概率建模的情况下，隐式学习目标

数据分布。扩散模型则在本质上采用不同的思路，通过学习逆向逐步添加噪声的过程。这些模型分为两个阶段：正向扩散过程逐渐向真实数据添加高斯噪声，直到其变为纯噪声；而反向过程则学习逐步去除噪声以生成新样本。扩散模型的随机解码过程用概率生成取代了确定性重建，从学习到的概率分布中采样并生成高质量图像，使其在极低码率下仍有较好表现。

GAN-based 模型与 Diffusion-based 模型的训练特性存在显著差异：GAN 通过对抗学习进行训练，使用相互竞争的损失函数，这可能导致训练不稳定、模式崩溃和收敛问题；相比之下，扩散模型采用更传统的去噪目标，并使用证据下界（ELBO）进行训练，从而实现了更稳定的训练过程。研究人员一直致力于结合这两种方法，试图使扩散模型像 GAN 一样只需一步即可完成训练，同时保持其训练稳定性和输出质量。此外，扩散模型与生成对抗网络（GAN）在图像生成和压缩上存在显著区别。GAN 依赖于确定性重建过程，通过固定的生成器将随机噪声映射到图像，这可能导致模式崩溃和缺乏多样性。而扩散模型采用概率生成方法，通过逐步引入随机性，从学习到的概率分布中采样，生成多样且清晰的图像。这种随机解码过程，使得扩散模型能够在失真和感知质量之间实现灵活的权衡，尤其在超低比特率压缩中表现出色，能够合成细节而非显式存储它们。这种迭代精炼的过程，使得扩散模型更有效地捕捉复杂数据分布，降低了对比特率的依赖，提升了生成图像的质量与多样性。

当扩散模型被迫在仅一步中生成图像时，它们的工作方式会发生根本性的变化，开始表现得像 GAN 训练。最直接的条件是用仅一步去噪训

练扩散模型时，这实际上将训练过程转变为传统的 GAN 训练。这种情况发生的原因在于，一步生成违背了扩散模型的基本原理，后者依赖于多个迭代的去噪步骤，以逐渐揭示数据分布。

如**错误!未找到引用源。**所示，反向去噪过程同样基于高斯假设，神经网络被训练以学习逼近真实反向扩散过程的高斯分布参数。通常，随机先验遵循标准高斯分布，而去噪过程则使用神经网络估计的均值参数进行高斯分布的参数化。虽然在噪声水平足够小的情况下，反向扩散过程在理论上会是高斯的，但真实的反向过程是不可解的，必须通过学习的神经网络参数来进行近似。一步扩散模型与去噪条件生成对抗网络（GANs）之间的根本区别在于它们的分布建模假设及其对 KL 散度优化的影响。传统的扩散模型通常假设去噪分布可以用高斯分布来近似，但这一假设仅在去噪步长非常小的极限下成立，这需要在反向过程中进行大量步骤。当目标是通过将去噪步骤减少到很少步来实现快速采样时，DDPM 的 $p_{\theta}(x_{t-1}|x_t)$ 的过程所遵循的高斯假设将不再成立，且无法将 L2 重建应用于 KL 散度建模^[29]。

生成对抗网络（GANs）和扩散模型的局限性推动了混合方法的发展，试图结合它们各自的优势。混合方法中的一个关键创新是 Diffusion-GAN，它在训练和生成过程中都消除了对反向扩散链的需求，使得生成器能够在一步内将噪声映射到生成样本，同时训练和生成速度与普通 GAN 相当。这种方法利用对抗损失来学习去噪分布，而不是依赖于 KL 最小化，当仅用一步去噪进行训练时，有效地将训练简化为传统 GAN 的训练。

近期的发展集中在优化一步扩散模型以实现高保真生成的对抗蒸馏策略上。像对抗扩散蒸馏 (ADD^[30]) 和潜在对抗扩散蒸馏 (LADD^[31]) 的方法结合了得分蒸馏和对抗损失, 使基础模型能够在仅 4 步之内实现高图像质量。这些方法代表了首次实现单步、实时图像合成的基础模型。

当前的状态研究现状, 与其说一步式扩散会变成 GAN, 不如说该领域可能正在朝着将 GAN 和扩散模型视为互补方法的方向发展, 分别针对不同的使用场景进行优化。

3.3.4 损失函数与优化

基于扩散的图像压缩的优化涉及复杂的损失函数, 这些损失函数与传统压缩方法使用的有根本性差异。尽管传统的学习图像编码器通常优化失真度量 (例如 MSE), 但这种方法通常导致在低比特率下感知质量不令人满意。基于扩散的压缩中的基本损失函数结构建立在率-失真理论之上, 但融入了扩散特定的组件。大多数方法采用基本公式, 结合率和失真项, 其中率 R 代表量化潜在表示的熵计算, 失真 D 通常使用均方误差 (MSE), λ 控制率与重建质量之间的权衡。

感知质量增强是扩散压缩损失设计中的一项关键创新。系统可以包含额外的感知损失项, 通常使用 LPIPS 损失, 并通过拉格朗日乘子加权, 以在率、失真和感知质量之间创建三向权衡。该度量利用深度神经网络特征来评估与人类感知更紧密相关的感知相似度。LPIPS 已成为训练目标的标准组成部分, 像 OneDC^[23] 等方法将其作为感知损失与 L1 像素损失结合使用, 其他方法则将其与权重结合, 如 $\lambda_{\text{LPIPS}} = 0.5$ 。另外其他方法

将 L1 损失与感知 LPIPS 组件和额外的解码器特定 L2 损失结合，以提高训练的稳定性^[32]。复杂的多组件公式将率-失真损失与码本损失和噪声估计损失结合，通常需要仔细的超参数平衡和固定步长的微调策略，以消除训练与推理阶段之间的差异。这些综合损失公式使得在单一模型内实现自适应量化参数学习和最佳去噪步骤预测成为可能。

尽管基于扩散的图像压缩方法得到了广泛发展，并强调感知质量，基于扩散的压缩方法在诸如 LPIPS 和 FID 等已建立的感知指标上表现出色，但将 CLIP 基于的质量评估损失整合进来并未成为调研工作中的一个显著研究方向。CLIP（对比语言-图像预训练）模型在各种计算机视觉任务中证明了其价值，因为它们能够理解图像与文本之间的语义关系，这在理论上可以为压缩场景中的感知质量评估提供帮助^[5]。近期的进展集中在实现这些竞争目标之间的更好平衡。一些方法在像素级度量（如 PSNR）和语义度量（如 LPIPS）上都显示出显著的改善，而其他方法在保持可比的感知得分的同时实现了实质性的保真度提升，例如在保持 LPIPS 和 FID 性能的同时，PSNR 提高了 2 dB。感知损失的整合基于早期在生成压缩中的工作，结合了对抗损失，并探索了专门用于感知图像压缩的训练策略。

3.3.5 量化和噪声处理

传统的图像压缩量化方法，如 JPEG 中使用的采用固定的量化矩阵在频域中进行量化，会在过程中发生信息损失。然而，基于扩散的压缩由于去噪过程的迭代特性，引入了本质上不同的量化挑战。

Chu 等人的工作^[33]指出扩散模型中的主要量化挑战包括内部量化噪声和外部量化噪声。内部量化噪声发生在各个去噪步骤中，主要是由于在残差模块中的嵌入扩展了激活量化范围，增加了干扰。外部量化噪声源于整个去噪过程中的累积量化偏差，逐步改变数据分布。这些累积效应与传统压缩方法有显著不同，在传统方法中，量化仅发生一次。

Relic 等人的工作^[34]的突破贡献是将量化误差视为可以通过扩散去噪去除的噪声。这种方法利用了量化误差与噪声之间的相似性，使扩散模型能够在量化过程中丢弃可以在扩散过程中合成的信息。这一公式允许传输量化图像潜在值，随后进行与量化数据噪声水平相对应的一系列去噪步骤。为了应对特定挑战，作者后来又在另一工作^[19]中设计了先进的量化策略，提出了带有均匀噪声的通用量化，以解决离散化和噪声水平差距，其中通过均匀随机变量抖动的硬量化保持了分布特性，同时实现了熵编码。这种方法在微调基础扩散模型时，将高斯噪声替换为均匀噪声。针对不同压缩范式，开发了专门的量化方法。Park 等人的工作^[35]中提出在向量量化策略中采用 VQ-Residual 训练，将结构基础码和潜在空间中的学习残差进行分解，率自适应噪声调制根据所需比特率调整去噪强度。其他方法将压缩潜在值视为处于中间扩散状态的噪声变体，建立从压缩比特率到伪扩散时间步的映射。

3.3.6 基于残差的生成式扩散模型图像压缩分析

基于残差的扩散图像压缩的核心原则解决了标准扩散方法中的一个基本低效问题。传统扩散模型直接从纯噪声生成高质量图像，这要求同

时生成结构和纹理，给扩散模型带来了不必要的负担，并增加了资源成本。为了解决这一限制，基于残差的方法将生成过程从图像空间转移到残差空间，其目标变为生成配对高质量和低质量图像之间的残差。

其数学基础涉及定义残差为 $e = z_c - z_0$ ，其中 z_c 表示压缩的潜在特征， z_0 表示目标潜在特征。基于残差的扩散方法并不从纯噪声开始去噪过程，而是使用压缩的潜在特征结合轻微噪声构建起始点，然后通过两者之间转移残差来过渡到目标。这种方法显著减少了重建所需的去噪步骤，同时确保起始点保留了大部分来自压缩特征的信息，为后续细节生成提供了坚实的基础^[32]。

像 ResShift^[36]和 RDDM^[51]55 等工作表明，在原始数据和降级数据之间结合残差显著增强了重建质量。残差扩散框架创造了一个双重过程，其中残差扩散表示从目标到降级图像的定向扩散，而噪声扩散则表示随机扰动，残差优先考虑确定性，而噪声则强调多样性。这种预测和细化的方法使得采样效率远高于典型的扩散模型，因为扩散模型被训练为预测残差，采用加速采样的方法。

基于残差的方法还实现了更智能的比特分配。例如，不确定性引导的方法认识到在预测的高频部分中，大的不确定性导致大残差，相比之下，低不确定性的残差消耗更多比特，通过不确定性加权的率-失真优化实现更高效的压缩^[37]。

四、基准测试与性能指标的模型复杂度分析


生成式图像压缩的评估涉及一套与传统压缩方法不同的指标。尽管传统方法主要关注像素级的保真度度量，如均方误差（MSE）和峰值信噪比（PSNR），但生成式图像压缩方法越来越多地使用感知度量来更好地捕捉人类视觉偏好。Fréchet Inception Distance（FID）已成为评估生成式图像压缩感知质量的主要基准。这些指标测量从生成图像和真实图像中提取的特征分布之间的相似性，提供了对视觉质量的更全面评估。学习的感知图像块相似性（LPIPS）指标也被广泛采用来评估感知质量。该指标利用深度神经网络以一种与人类判断更相关的方式评估图像相似性，优于传统的像素级指标。用户研究在评估这些方法中也发挥了重要作用。通过与用户的互动，研究人员能够深入了解人们对图像质量的主观感受，从而更好地调整生成模型的参数，以满足用户的期望。例如，用户对图像细节、颜色准确性和整体视觉吸引力的反馈，可以帮助优化模型，使其在保持较低比特率的同时，尽量保留视觉质量。

4.1 基于 VQGAN 图像压缩的性能与复杂度分析

VQGAN 模型的计算复杂度受到计算成本与序列长度之间的平方关系的根本限制，使得直接对原始像素进行建模在计算上变得不可行。这一限制推动了 VQGAN 的核心设计理念，即通过在压缩的潜在空间而非像素空间中操作来解决可扩展性问题，从而通过离散的标记序列高效建模高分辨率图像。现代 VQGAN 实现展现出显著的效率提升，优化后的框架能够在消费者级 GPU（如 GTX 1080Ti）上大约 2 秒内生成多样化且真实的百万像素样本（ 1024×1024 ）^[6]。对于压缩应用，编码和解码管

道通过在学习的码本中进行高效的最近邻查找，然后进行算术压缩以生成比特流^[7]。本报告中聚焦在现在的最新的算法 DLF 中，汇总了其中的算法复杂度来为下一步提供技术分析。

From DLF ^[3]				
方法	数据集	编码时间	解码时间	服务器
DLF	Kodak	0.178	0.252	A100
DiffEIC	Kodak	0.152	4.093	A100
PerCo	Kodak	0.461	2.443	A100




4.2 基于扩散模型图像压缩的性能与复杂度分析

基于扩散模型的图像压缩的吸引力在于其实现高质量重建的潜力，以及从压缩表示中生成多样化输出的能力。然而，这种方法引入了与传统压缩方法显著不同的独特计算挑战。与单次传递的编码器-解码器架构不同，扩散模型在压缩和解压缩过程中都需要多个推理步骤，从而导致显著更高的计算成本。这些模型的迭代特性意味着时间复杂度和模型复杂度成为决定其在现实世界压缩应用中的实际可行性的关键因素。扩散


基础压缩中最显著的计算挑战源于去噪过程的迭代特性。传统的扩散模型需要数百个采样步骤，有些实现甚至需要多达 1000 个扩散步骤才能生成高质量图像。这造成了一个根本性的瓶颈，生成单张图像需要多次应用深度神经网络，使得这种方法在当前形式下显得不切实际。实证测量揭示了这一计算负担的规模。由于部分代码开源，本项目报告中汇总了具有竞争力的扩散模型图像压缩方法上的编码和解码的时间，已经在不同数据集上的性能对比。

From Stable Codec ^[5]					
方法	数据集	编码时间	解码时间	服务器	步长
StableCodec	Kodak	0.159	0.326	RTX 3090	1
DiffEIC	Kodak	0.676	7.423	RTX 3090	50
PerCo	Kodak	0.287	3.742	RTX 3090	20
Text +Sketch	Kodak	113.252	33.560	RTX 3090	25




From MRIDC ^[4]					
方法	数据集	编码时间	解码时间	服务器	步长
MRIDC	Kodak	0.078	1.28	A800	20

PerCo	Kodak	0.04	0.98	A800	20
PICS	Kodak	221.10	42.80	A800	25




From DiffO					
方法	数据集	编码时间	解码时间	服务器	步长
DiffO	CLIC2020	0.136	0.253	Titan RTX	-
DiffEIC	CLIC2020	0.801	12.502	Titan RTX	-
CDC	CLIC2020	0.038	10.7428	Titan RTX	-



From OneDC

方法	数据集	编码时间	解码时间	服务器	步长
OneDC	MS-COCO 30K	0.15	0.34	A100 G	
DiffC	MS-COCO 30K	3.9	6.9	A100 G	
PerCo	MS-COCO 30K	0.58	8.80	A100 G	
DiffEIC	MS-COCO 30K	0.32	12.4	A100 G	



五、技术迁移至低复杂度的 AI 编码器思路设计

5.1 损失函数的影响

生成图像压缩中的损失函数演变始于引入对抗训练，以克服传统失真度量的局限性。Rippel 等人的工作^[38]中首次提出在端到端框架中使用对抗损失函数，以提高视觉质量，认识到传统度量如 PSNR 和 MS-SSIM 在非常低比特率下失去意义，此时像素级的保留变得不如保持纹理和全局结构重要。这项基础工作确立了对抗损失能够比传统失真度量更有效地捕捉全局语义信息和局部纹理的认识。在此基础上，后续研究扩展了生成对抗网络在压缩系统中的应用。

随着扩散模型的集成，损失函数进一步演变，这些模型引入了超越传统对抗损失的新训练目标。基于扩散的压缩方法^[39]使用加权变分界限

和去噪得分匹配技术，实现了高视觉质量。这些方法可以端到端训练，并且相比纯生成方法提供了显著更短的编码时间。

现代损失函数变得越来越复杂，结合多个组件来解决压缩质量的不同方面。当代方法将失真损失与来自深度卷积网络特征的感知损失度量结合，创建加权和，以平衡像素级差异与感知相似性。率失真优化被扩展为率-失真-感知权衡，学习目标不仅最小化率和失真，还确保重建与基础数据分布一致。最近 Qi 等人的工作^[40]中包括基于代码预测的损失函数，旨在增强生成压缩系统中的语义一致性。这些高级损失公式解决了生成模型优先生成高质量内容而没有比特率监督的根本挑战，而压缩技术必须在有限比特率内有效表示图像，这在生成过程的随机性与比特率约束之间产生了内在冲突。

5.2 先验的影响

生成图像压缩中的先验建模经历了显著的发展，首先认识到传统的熵模型不足以捕捉复杂的图像统计信息。早期的方法^[41]使用完全分解的先验，但最近的研究通过使用信息变换器等先进架构，利用注意力机制增强了先验模型，从而改善了压缩性能，并通过特征优化技术减少了最佳特征与网络生成表示之间的距离^[42]。

生成模型的引入标志着先验建模方法的根本转变。最初，生成对抗网络作为生成图像压缩系统中的解码器，提供了通过学习合成无法存储的真实细节实现超低比特率压缩的潜力。2022 年后，扩散模型逐渐取代 GAN，成为首选的生成先验，提供了通过多模态条件化增强的能力。这

些模型可以通过对比语言-图像预训练（CLIP）编码的文本和边缘数据等多模态信息进行约束，结合去噪扩散隐式模型（DDIM）、潜在扩散（LD）和稳定扩散等重建模型，实现超低比特率压缩^[43]。扩散模型在使用随机编码方法时非常适合作为解码器，并且可以进行端到端训练，导致相比纯生成方法显著缩短的编码时间。

然而，目前的生成压缩方法在其先验建模方法上面临着一个关键限制。尽管这些方法在生成高频细节方面有效，但往往忽视了对图像内容的先验分布建模，而这对于在极端压缩场景（每像素低于 0.05 比特）中实现进一步比特率降低至关重要。最近的创新通过新颖的方法解决了这些限制，例如生成潜在编码（GLC^[44]）模型，该模型在生成向量量化变分自编码器的潜在空间中进行变换编码。这些潜在空间提供了更大的稀疏性、丰富的语义以及更好的人类感知对齐，展示了在实现高真实感和高保真压缩方面的优势。此外，现代方法结合了空间分类超模块和时空分类超模块，以增强先验建模性能。

5.3 简化 VQGAN 图像压缩的技术路线

尽管 VQGAN-based 压缩方法在高感知质量和低比特率方面具有优势，但其原始结构通常涉及复杂的卷积网络、Transformer 模块以及大型码本，不适合直接部署于计算资源受限的平台。对于较低复杂度的场景，需从编解码结构优化、码本设计、区域冗余适应性策略等多个方面进行针对性设计。

在编码器结构方面，VQGAN 的 Encoder 通常基于 ResNet、UNet 或

Transformer 主干，用于提取深层次潜在表示。这类结构虽能提取有效的上下文信息，但其运算量和参数量显著高于轻量网络，导致部署瓶颈。近年来如 DLF^[3]与 Fine-tuned VQGAN^[7]等工作探索使用模块简化编码器复杂度的方式，表明可通过替换主干网络为轻量级模型（如 MobileNet、EfficientNet-lite、GhostNet）来显著减少模型体积和推理延迟。同时，在多篇近期工作中使用的双分支结构虽然提升了表示能力与压缩性能，但也显著增加了推理时的存储与计算资源占用。因此，为保持轻量化，可用统一主干加动态注意力机制或可学习区域引导替代结构分裂，从而在保持分区编码能力的同时削减模型规模

在解码器端，为了减轻设备负担、提高可部署性，一种可行思路是将复杂重建模块推迟至解码端或云服务器执行，即采用“轻编码-重解码”结构。在 Fine-tuned VQGAN、HDCompression 与 DiffPC 等工作中，普遍采用“结构编码+高质量重建”的思路，编码器侧仅传输简化的结构语义索引，而服务端则进行高质量的推理重建。这类方式不仅可以在编码端降低计算负担，也便于在服务端集成更强生成模型（如 DDPM 或 Latent Diffusion）以增强图像细节。例如，HDCompression 提出使用局部块重建+细节补偿的混合策略，不依赖全图解码，从而减少显存占用；DLF 则进一步通过双分支潜变量融合生成图像细节，有效减少解码冗余。

在码本设计上，针对 VQGAN 模型中离散码字索引带来的存储冗余问题，可采用小型化的向量码本设计。例如，在 GLC^[44]中使用类别监督结合小规模码本，维持感知表达能力的同时压缩整体表示长度。同时，引入 Group-VQ（分组向量量化）机制可以使一个较大的码本被划分为若

干小组，每次只激活部分子码字，减少一次性查表成本。Control-GIC^[11]则进一步提出多粒度表示，通过细粒度 token 与粗粒度索引结合，实现编码粒度的灵活控制。此外，在 MRIDC^[4]等工作中还引入了区域掩码机制，在编码阶段对图像中非重要区域进行空白量化或掩码填补，节省码率同时降低量化计算量。

对于图像压缩任务中的区域冗余问题，近年来诸多工作提出显著性优先编码机制，代表性如 SQ-GAN^[9]与 MRIDC。这些方法在编码过程中引入轻量掩码预测模块，通过初步分析图像语义与纹理复杂度，仅保留显著区域进行编码，而平坦区域则可跳过或使用统一占位码表示。这种方法在不显著影响视觉感知质量的前提下，可有效减小编码器工作负荷，降低比特流大小，同时节省设备端的编码时延和计算成本。同时，ALIT^[2]提出的递归式资源分配策略（Recurrent Allocation）使图像的潜在表示可以按照区域的重要性与复杂度自动分配 token 数量，实现区域粒度的动态不均衡化编码。该机制不仅有效避免了对简单区域的过度编码，还支持 token-level 的 early-stop 与跳跃处理，显著减少了计算与传输开销。

5.4 简化扩散模型的图像压缩技术路线

5.4.1 单步扩散图像压缩

扩散模型在图像压缩方面展现出了巨大的潜力，但其原始实现往往过于复杂和缓慢，不适用于现实世界的应用。这项技术利用神经网络学习以受控方式对图像进行加噪和去噪，从而实现很好的压缩比。然而，主要挑战在于这些模型通常需要很多步骤来生成或重建图像，这使得它

他们在日常应用中显得不够实用。扩散模型采用概率生成方法，通过逐步引入随机性，从学习到的概率分布中采样，生成多样且清晰的图像。这种随机解码过程，使得扩散模型能够在失真和感知质量之间实现灵活的权衡，尤其在超低比特率压缩中表现出色，能够合成细节而非显式存储它们。因此，研究人员开始专注于简化这一方法，通过减少扩散步骤、优化模型架构以及开发更快速的采样方法来应对这一问题。目标是保持扩散模型所能产生的高质量结果，同时使其足够快速且简单，能够真正部署在实际的压缩系统中。

基于扩散的图像压缩的核心简化方法主要集中在显著降低计算复杂性，同时保持高质量的结果。最重要的突破是转向单步扩散，研究人员已经证明一个去噪步骤足以实现高质量重建。与传统扩散模型需要数十个迭代步骤相比，这代表着巨大的效率提升。

OneDC^[23]的方法通过一次生成实现了最先进的感知质量，相比于多步方法，提供了超过 40% 的比特率减少和 20 倍的解码速度提升。这一效率突破使得基于扩散的压缩在实际部署中变得可行，同时区别于传统 GAN 架构的随机解码过程也保持了其质量优势。




图 4 OneDC 模型结构示意图

5.4.2 单分支编码双分支解码架构设计

另一个主要的简化方法是设计单分支编码器双分支解码器策略，在这种方法中，扩散模型仅在增加最大价值的地方被选择性使用。研究人员并没有完全替代整个压缩流程，而是通过优化现有的编码和解码结构来提高效率。这种方法利用单分支编码器提取图像的主要特征，同时采用双分支解码器来分别处理高频和低频信息。具体来说，编码器负责将输入图像转换为一个潜在表示，而双分支解码器则分别从不同的解码路径重建图像。一个分支专注于重建图像的基本结构和低频信息，另一个分支则处理细节和高频信息。这种策略的优势在于能够有效地利用扩散模型的强大生成能力，同时避免不必要的计算开销。此外，通过选择性地应用扩散模型，研究人员能够在需要时增强图像的细节表现，而在其他情况下则保持计算资源的高效利用。这种灵活性使得模型在处理复杂场景时能够更好地平衡质量和速度，最终实现更高效的压缩效果。进一步的研究可以探索如何在不同类型的图像和应用场景中优化这一策略，以达到最佳性能。

5.4.3 LoRA 微调训练

基于 LoRA 微调，基础模型的先验应用可能是最实用的简化方法。研究人员使用预训练的扩散模型，如 Stable Diffusion，进行最小修改，以适应特定任务的需求。这种方法通过在已有的强大模型上进行微调，能够快速实现高质量的生成效果，同时减少训练时间和计算资源的消耗。他们并没有从头训练特定于压缩的扩散模型，而是添加小的控制模块或直接使用预训练模型，从而大幅减少训练需求。具体而言，LoRA 通过引

入低秩矩阵来调整模型的权重，只需对少量参数进行更新。这种方式使得微调更加高效，能够在保持基础模型性能的同时，针对特定数据集进行优化。此外，由于只有一部分参数被训练，模型的内存占用也显著减少，适合在资源受限的环境中应用。进一步的优化策略包括选择性冻结基础模型的某些层，仅对特定层进行微调，以减少过拟合的风险并加速训练过程。同时，研究人员还可以通过集成不同的微调策略，结合其他技术如数据增强和知识蒸馏，以进一步提高生成图像的质量和多样性。

六、未来方向探索

6.1 基于扩散的图像初步压缩方案

基于扩散的图像压缩领域正处于一个关键的交叉点，必须解决几个根本性挑战以实现广泛应用。计算效率仍然是最紧迫的问题，尽管最近的进展将压缩时间缩短，但当前方法仍需比传统编解码器需要更多的处理时间。尽管这些计算成本仍然是一个显著障碍，但相关研究表明扩散模型和后验采样技术的持续进展可能会显著降低这一限制。未来的工作必须集中在开发单步或少步的扩散过程，以便能够达到实际应用中期望的毫秒级编码和解码速度。

- 一个有前景的方向是开发一阶段解码替代方案，消除多步骤采样的需要。阻碍有效一站式扩散的核心限制在于传统扩散模型理论所依赖的高斯分布假设。标准的扩散模型假设去噪分布可以近似为高斯分布，但这一假设仅在前向扩散过程中添加的噪声较小时有效。当研究人员试图使用更大的去噪步骤来加快采样时，反向

扩散分布变成了非高斯的多模态分布，这违反了理论基础，并导致生成样本的偏差。这种根本的不匹配解释了为什么一站式扩散在传统高斯框架下会面临困境。其根本原因在于扩散模型的归纳偏差，即图像是从纯噪声逐渐重建的，每一步都是基于高斯分布进行估计。当试图在一步之内将噪声恢复为连续图像时，这一假设完全崩溃。结果是，使用更少的去噪步骤导致训练不稳定和输出质量下降，尤其是在复杂生成设置中。

- 最近的方法引入了双分支框架，将图像重建分解为专门的组件，以提高整体压缩效果。一种显著的策略是分离语义处理和细节处理，其中语义分支将高级信息聚类为紧凑的标记，而细节分支则编码感知上关键的细节，以增强重建的保真度。这种分解使得每个分支可以针对其特定角色进行优化，并且跨分支的互动设计有助于减少两个路径之间的冗余，最小化整体比特成本。双解码器方法结合了传统自编码器重建与基于扩散的细化，在这种混合架构中，常规解码器首先生成一个初步重建，优化用于失真度量，随后由扩散模型细化图像，通过预测残差信息来提升感知质量。这种顺序处理使系统能够保持良好的失真表现，同时利用扩散模型的生成能力增强感知质量。
- LoRA 微调已成为一种关键技术，能够高效地将大型预训练的扩散模型适应于图像压缩任务，而无需全面微调模型的计算开销。在基于扩散的压缩系统中，LoRA 层被集成到像 Stable Diffusion 这样的预训练模型的编码器和去噪组件中，同时保持解码器不变，

以保留丰富的生成先验。这种选择性适应方法允许模型学习特定于压缩的特征，同时保持在预训练过程中发展起来的强大图像生成能力。LoRA 微调在压缩应用中的有效性通过像 OneDC 这样的框架得以验证，该框架利用 LoRA 适应实现了压缩任务的快速收敛，同时保留生成先验。这种方法带来了显著的性能提升，系统实现了超过 40% 的比特率减少和 20 倍的解码速度提升，相比于现有的多步扩散编解码器，同时所需的可训练参数远少于全面微调模型。LoRA 的参数效率使其在内存和计算资源受限的部署场景中特别有价值。

6.2 标准化

基于扩散的压缩方法的标准化也是一个重大挑战，当前的方法缺乏统一的框架和兼容性标准，而这些标准是传统编解码器实现广泛应用的基础。未来的工作必须解决不同扩散架构之间的互操作性，并开发可在不同实现中可靠解码的标准化格式。提案[VC-54-M466]提出探索一种混合图像压缩方案，该方案将扩散模型与端到端压缩模型相结合。该方案首次引入了一种基于扩散的图像压缩方法，该方法利用特权的端到端解码器模型进行修正。通过在编码器端传输从原始图像提取的额外特权信息，并将其用于解码端扩散模型与端到端模型的集成，可以在保证一定失真的同时获得更好的感知质量。该方法的主要架构如图下所示。在编码器端，该方法结合了扩散解码器和端到端解码器的结果，并通过从原始图像获取的监督得到的线性因子进行组合。然后，位率和因子都被发送到解码器端。在解码器端，位率由两个解码器解码，而线性因子直接

用于组合它们。





图 5 提案[VC-54-M466]模型结构示意图

模型结构中训练了 4 个模型，逐步增加参数数量。模型中扩散解码器的设置及其参数数量如下表所示。4 个模型的端到端部分均为 ELIC。所有模型均采用两个阶段的训练，批量大小均为 8。训练数据集为 DIV2k。在第一阶段，我们仅训练所有 3 个模型的扩散部分，同时固定端到端编码器和解码器，迭代 400,000 次，学习率为 $1e-4$ 。

Setting	number of channels	channel multiples	attention	number of parameters (only diffusion part)
S	96	1, 1, 2, 2, 3	w/o	40.0M
M	96	1, 2, 2, 3, 3	w/o	53.2M
L	128	1, 2, 2, 3, 3	w/o	90.5M

在 CLIC 专业数据集上评估所有模型。9 项指标的表现如下：



6.3 扩散图像压缩编码器深度分析

图像压缩是一项关键技术，旨在减少文件大小，同时尽量保持图像质量。传统方法如 JPEG 已经成为标准数十年，但它们在低比特率下常常会产生块状伪影，并且会丢失细节。近年来，学习型图像压缩作为一种强大的替代方案应运而生，它使用神经网络更高效地编码和解码图像，相比传统编解码器具有更好的性能。这些学习型方法通过在大量自然图像数据集上进行端到端训练，可以实现更好的率-失真性能。

该领域最新的发展是基于扩散的生成图像压缩，这种方法采用扩散模型——同样类型的生成 AI，驱动图像创建工具。与传统压缩方法仅仅试图重建原始图像不同，基于扩散的方法可以生成感知上相似的图像，

这些图像在相同比特率下可能看起来比传统压缩产生的效果更好。这标志着从纯粹的重建压缩向生成压缩的转变，其目标是感知质量而非像素级的完美重建。

6.3.1 扩散图像压缩范式优势来源

基于扩散的压缩技术最显著的技术优势在于其能够生成比传统自编码器方法更具感知真实感的重建。虽然传统的学习压缩方法（如使用变分自编码器 VAE）直接优化低失真指标（如均方误差 MSE 或平均绝对误差 MAE），但它们受到模式平均行为的影响，导致重建图像模糊。基于扩散的方法通过用更具表现力的条件生成模型替换确定性的高斯解码器，解决了这一根本限制，在感知指标上实现了最佳报告性能，同时与现有压缩模型保持竞争力。例如，在比特率低于 0.1 bpp 的情况下，传统的最先进方法会出现模糊伪影，而基于扩散的方法能够生成非常清晰的细节，有时甚至比原始图像更锐利。在极低比特率下，性能提升尤为明显。像 PerCo 这样的算法在低至 0.003 bpp 的比特率下实现了逼真的重建，这比大多数先前工作的考虑比特率小一个数量级以上。StableCodec 中在这些极端压缩级别下，基于扩散的编解码器可以将一幅 512x768 的 Kodak 图像压缩到不足 153 字节，同时保持重建逼真图像的能力。在具体指标方面，基于扩散的压缩在感知质量分数上始终优于最先进的方法。这些方法在感知相似性指标（如 LPIPS 和 FID）上表现出色，这些指标与人类主观感知更紧密相关，而传统方法则专注于像素级准确性指标（如 PSNR 和 SSIM）^[45]。用户研究确认，基于扩散的重建在质量上更受最终用户的偏好，显示出它们在以人为本的压缩应用中的有效性。

一个关键的技术优势在于利用来自预训练基础模型的强大生成先验。最近在大规模文本到图像的潜在扩散模型中的突破揭示了可以重新用于压缩任务的生成先验。通过结合这些强健的生成先验，基于扩散的方法能够将更多比特分配给低频信息，同时利用生成先验合成高频细节，实现极端压缩比而不牺牲图像保真度。这一方法与传统学习压缩方法纯粹专注于率-失真优化形成对比，后者在低比特率下由于模糊和过度平滑而导致视觉效果不佳。

基于扩散的压缩技术的第二个优势在于其随机解码过程，它用概率生成取代了确定性重建。与传统的变分自编码器（VAE）由于模式平均行为和模糊性而受到限制不同，扩散模型能够通过从学习到的概率分布中采样，生成清晰、细致的图像。这种随机方法提供了失真与感知质量之间可控的权衡，增加随机性通常会提高视觉吸引力，但代价是像素级的准确性差，表现为 PSNR 差。随机特性使得扩散模型在严格的码率约束下表现优异，通过合成纹理和细节而不是显式存储它们来实现。这一能力使得超低比特率压缩成为可能。扩散解码的生成特性使得这些模型在比特率上相比传统编解码器的依赖性降低。相比于基于 CNN 的方法依赖于确定性的编码-解码架构，将输入压缩到低维潜在空间并进行单步重建，但扩散模型引入了一个随机过程，通过噪声逐渐过渡到完全重建的图像，从而能够捕捉更复杂的数据分布。这种迭代精炼过程使得扩散模型在潜在空间中更有效地建模概率结构。

基于扩散的方法在感知质量上的优势源于它们能够优化率-失真-真实感的权衡，而不仅仅是率-失真。虽然传统的 CNN 压缩方法专注于像

素优化, 未能与人类感知和语义一致性对齐, 因为缺乏感知和对抗监督, 但基于扩散的方法通过将扩散知识整合到编码和解码过程, 能够生成详细、真实的图像。另一个技术优势是提高了可扩展性和灵活性。基于扩散的方法能够利用量化误差与加性噪声之间的相似性, 使得扩散模型更有效地“去噪”由量化引入的伪影。扩散解码的迭代随机特性通过其逐步精炼过程, 相较于单步确定性方法提供了显著的优势。Zhao 等人的工作^[46]指出, 即使是单步变体的扩散解码器也优于普通的 VAE 解码器, 而额外的步骤进一步提高质量, 提供了计算与视觉保真度之间可控的权衡, 能够根据应用需求在推理时进行调整。

6.3.2 扩散模型噪声的作用

噪声过程通过两个相互关联的马尔可夫动态构成扩散压缩的基础。前向扩散过程系统地向数据添加噪声, 通过一系列转换逐渐侵蚀结构, 直到图像几乎无法与纯噪声区分开来。该过程遵循一个受控的方差调度, 该调度可以是固定的或学习得到的, 使得扩散过程基本上是参数无关的, 仅需这一调度组件。然后, 反向过程使用神经网络通过预测去噪状态来迭代恢复数据, 训练目标是通过噪声预测目标来逼近真实的去噪转换, 其中模型学习预测在每一步添加的特定噪声 ϵ 。扩散压缩中的一个关键见解是噪声如何使内容和纹理信息得以分离。压缩框架将在紧凑的潜变量中捕捉必要的内容信息, 而剩余的纹理细节则在解码过程中通过受控的噪声过程合成。这种分离使得去噪解码器能够从内容潜变量中确定性地重建数据, 而反向扩散过程则逐步重建更细的纹理细节。噪声预测网络专门训练, 以确保在每个反向过程步骤中预测的噪声保持与前向扩散过

程中引入的噪声相同的分布，通常使用 L2 损失进行优化，以最小化实际噪声与预测噪声之间的差异。

量化扩散模型用于压缩的过程产生了新的噪声源，需要额外的去噪，从而显著降低了扩散模型的采样效率。Chu 等人的工作^[47]分析这种效率损失是显著的——量化扩散模型在经过 30 步后达到了 194.11 的 FID 指标，而在仅经过 10 步后，其性能仍低于全精度模型。除了效率问题，量化噪声还根本改变了扩散模型的迭代方向，使其偏离最佳去噪路径。这种方向变化表现为可测量的性能下降，量化模型在第 25 步时与全精度模型相比，CLIP 分数差异达到 3.16% (26.09% vs. 29.25%)。在每个步骤中产生的内部量化噪声与整个采样过程中积累的外部量化噪声加剧了这些问题，需要专门的方法来估计和过滤累积的量化效应。

6.3.3 扩散模型去噪多步的合理性

基于扩散的压缩效果受到压缩和解压过程中遇到的不同噪声类型的统计特性之间基本不匹配的显著影响。一个主要问题源于噪声类型差距，即量化误差与标准扩散模型中内置的高斯噪声假设之间的分布差异。尽管在许多领域，特别是潜在领域，信号处理文献^[48]已证明量化误差可以被近似为均匀噪声，但扩散模型本质上假设高斯噪声结构。这种分布不匹配在高斯去噪模型与均匀量化噪声交互时会产生显著的实际问题。模型无法正确预测实际的噪声特性，导致生成伪影，从而严重降低重建质量。这种不匹配的具体表现包括视觉上令人不悦的效果，如不自然的颜色偏移、纹理不一致和人工模式，这些都会损害生成图像的保真度。

除了噪声类型差距，扩散压缩系统还面临与噪声水平不匹配相关的挑战，其中部分噪声数据的预期信噪比与压缩过程中实际遇到的比率之间存在差异。这些差距导致数据超出扩散模型训练时的分布，从而对最终的重建质量产生负面影响。先进的压缩框架已开始通过自适应方法解决这些分布不匹配的问题，这些方法考虑了不同的噪声统计特性。例如，内容自适应系统可以根据局部噪声特性调整量化策略，其中噪声水平较高的区域采用较大的量化步长，而结构内容丰富的区域则采用较细的量化步长。解决噪声类型差距的具体方法是使用均匀噪声而非高斯噪声训练扩散模型，从而匹配实际遇到的量化误差的分布。

多步骤去噪方法提供了几种策略，以应对基于扩散的图像压缩中的噪声和分布不匹配问题。关键见解在于利用量化误差与噪声之间的相似性，执行与量化潜变量实际噪声水平相对应的有针对性的去噪步骤。这种方法使系统能够预测和执行最佳数量的去噪步骤，具体取决于比特率。

多步骤去噪的有效性在于从已经包含结构和语义信息的量化潜变量开始，而不是纯噪声。这种根本差异意味着执行整个去噪步骤范围既浪费又会导致图像过度平滑，因此步骤优化至关重要。较低的比特率通常需要更多的去噪步骤以实现高感知质量，但这一关系必须与计算成本和解码速度进行权衡。更复杂的方法涉及与比特率相关的噪声调制策略，在推理时调整噪声强度，以确保感知质量与效率之间的最佳平衡。**Park** 等人的工作^[35]指出，对于采用激进量化的低比特率，在反向扩散过程中进行更强的噪声注入，使模型能够执行更强的一步修正，弥补细节损失，而无需多次迭代。然而，仍然存在一个根本挑战，即多步骤去噪过程中

生成噪声预测与需要干净图像的单步度量计算之间的不匹配。

6.3.4 双分支策略及残差策略分析

为了应对单支路扩散方法的局限性，开发了双支路编码框架，这些框架显著提高了重建质量和效率。这些架构引入了一对辅助编码器和解码器组件，与主扩散模型协同工作，以增强性能。双支路方法解决了传统扩散压缩方法中使用的预训练变分自编码器（VAE）编码器的关键弱点。辅助编码器专门设计了速率失真优化，嵌入了更多关注熵的语义信息，从而导致更好的编码决策。这种针对性的设计有助于弥合预训练编码器的通用性与压缩任务的特定需求之间的差距。在解码方面，辅助解码器在重建过程中执行结构分配，为单步去噪操作提供改进的生成指导。这种增强的指导机制相比于传统的指导技术，能够生成更一致的细节，而传统方法在极低比特率时往往表现不佳。双支路架构的有效性在极低比特率时尤为明显，此时常规扩散模型往往会生成无关内容。虽然传统的基于扩散的方法依赖于各种指导技术，但仍然产生次优的重建保真度，而双支路编码框架则提供了增强的保真度、竞争力的真实感和显著更快的解码速度。扩散模型引入的固有不确定性加剧了量化挑战，因为从高斯噪声中采样的随机性造成的不稳定性影响后续的压缩阶段。这种不确定性在预测不确定性较高的区域表现为较大的残差，消耗的比特数超过了不确定性较低的区域。量化效应与采样不确定性的结合可能导致颜色失真和伪影，特别是当反向过程从随机采样的高斯噪声开始时，这突显了需要考虑量化和采样变异的基于不确定性的压缩策略。

基于残差的缓解策略代表了应对传统基于扩散的图像压缩根本局限性的关键进展^[49]。这些方法并不是从纯噪声开始重建，而是利用了一个洞察，即解码器输出与原始图像之间的残差更容易建模，因为它们大致遵循正态分布，这可以显著减少所需的采样步骤数量。中继残差扩散框架通过结合压缩的潜在特征和最小噪声来构建起始点，然后通过在这些起始点与目标潜在特征之间移动残差来进行转换。这种方法确保起始点保留了大部分来自压缩特征的信息，为后续细节生成提供了坚实的基础，同时显著减少了重建所需的去噪步骤数量。在实践中，基于残差的框架通常采用两阶段解码过程，其中轻量级解码器首先生成经过保真度优化的重建，然后由潜在条件的残差扩散模型添加额外细节，以微调图像的感知质量。这种预测与精细化的方法使得采样效率远高于典型的扩散模型，同时在失真度量和感知质量上保持了竞争力。

6.3.5 蒸馏方式对提升主观性能影响

扩散模型的计算负担较重，推理时需要数十个去噪步骤，这推动了蒸馏技术的发展，以加速生成过程。大多数单步扩散（OSD）方法采用蒸馏来从教师模型中学习，同时保持图像保真度，因为过度减少推理步骤通常会导致性能下降。

分布匹配蒸馏（DMD^[50]）已成为一种显著的方法，它将扩散模型转变为单步图像生成器，对图像质量的影响最小。DMD 通过强制单步生成器在分布层面上与扩散模型匹配，最小化一个近似的 KL 散度，其梯度可以表示为两个评分函数之间的差异——一个来自目标分布，另一个来

自单步生成器生成的合成分布。

在图像压缩的背景下，扩散蒸馏已被调整以增强语义指导并提高模型效率。近期的研究利用超先验作为单步扩散模型中的文本指导替代，通过将扩散蒸馏损失与潜在空间中的对抗损失相结合，提升了其语义能力。这些方法表明，蒸馏能够实现显著的性能提升，一些方法在推理成本上减少高达 500 倍的同时，达到与完整扩散模型相当的质量。

七、参考文献

- [1] Esser P, Rombach R, Ommer B. Taming transformers for high-resolution image synthesis[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 12873-12883.
- [2] Duggal S, Isola P, Torralba A, et al. Adaptive length image tokenization via recurrent allocation[C]. First Workshop on Scalable Optimization for Efficient and Adaptive Foundation Models. 2024.
- [3] Xue N, Jia Z, Li J, et al. DLF: Extreme Image Compression with Dual-generative Latent Fusion[J]. arXiv preprint arXiv:2503.01428, 2025.
- [4] Xu J, Wang S, Chen J, et al. Decouple Distortion from Perception: Region Adaptive Diffusion for Extreme-low Bitrate Perception Image Compression[C]. Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 18051-18061.
- [5] Zhang T, Luo X, Li L, et al. StableCodec: Taming One-Step Diffusion for Extreme Image Compression[J]. arXiv preprint arXiv:2506.21977, 2025.
- [6] McKinney A F, Willcocks C G. Megapixel Image Generation with Step-Unrolled Denoising Autoencoders[J]. arXiv preprint arXiv:2206.12351, 2022.
- [7] Mao Q, Yang T, Zhang Y, et al. Extreme image compression using fine-tuned vqgans[C]//2024 Data Compression Conference (DCC). IEEE, 2024: 203-212.
- [8] Zhu L, Wei F, Lu Y, et al. Scaling the codebook size of VQ-GAN to 100,000 with a utilization rate of 99%[J]. Advances in Neural Information Processing Systems, 2024, 37: 12612-12635.

- [9] Pezone F, Barbarossa S, Caire G. SQ-GAN: Semantic Image Communications Using Masked Vector Quantization[J]. arXiv preprint arXiv:2502.09520, 2025.
- [10] Xia Y, Zhou Y, Wang J, et al. DiffPC: Diffusion-based High Perceptual Fidelity Image Compression with Semantic Refinement[C]//The Thirteenth International Conference on Learning Representations.
- [11] Li A, Li F, Liu Y, et al. Once-for-all: Controllable generative image compression with dynamic granularity adaption[J]. arXiv preprint arXiv:2406.00758, 2024.
- [12] Yang R, Mandt S. Lossy image compression with conditional diffusion models[J]. Advances in Neural Information Processing Systems, 2023, 36: 64971-64995.
- [13] Ghose N F, Petersen J, Wiggers A, et al. A residual diffusion model for high perceptual quality codec augmentation[J]. arXiv preprint arXiv:2301.05489, 2023.
- [14] Mao R, Feng X, Gao C, et al. Perceptual Image Compression With Conditional Diffusion Transformers[C]//2024 IEEE International Conference on Visual Communications and Image Processing (VCIP). IEEE, 2024: 1-5.
- [15] Careil M, Muckley M J, Verbeek J, et al. Towards image compression with perfect realism at ultra-low bitrates[C]//The Twelfth International Conference on Learning Representations. 2023.
- [16] Bordin T, Maugey T. Semantic based generative compression of images for extremely low bitrates[C]//2023 IEEE 25th International Workshop on Multimedia Signal Processing (MMSP). IEEE, 2023: 1-6.
- [17] Li Z, Zhou Y, Wei H, et al. Towards extreme image compression with latent feature guidance and diffusion prior[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2024.
- [18] Lei E, Uslu Y B, Hassani H, et al. Text+ sketch: Image compression at ultra low rates[J]. arXiv preprint arXiv:2307.01944, 2023.
- [19] Relic L, Azevedo R, Zhang Y, et al. Bridging the Gap between Gaussian Diffusion Models and Universal Quantization for Image Compression[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 2449-2458.
- [20] Bordin T, Maugey T. Linearly transformed color guide for low-bitrate diffusion based image compression[J]. IEEE Transactions on Image Processing, 2024.
- [21] Ke A, Zhang X, Chen T, et al. Ultra Lowrate Image Compression with Semantic Residual Coding and Compression-aware Diffusion[J]. arXiv preprint arXiv:2505.08281, 2025.
- [22] Elata N, Michaeli T, Elad M. Zero-Shot Image Compression with Diffusion-Based Posterior Sampling[J]. 2024.

- [23] Xue N, Jia Z, Li J, et al. One-Step Diffusion-Based Image Compression with Semantic Distillation[J]. arXiv preprint arXiv:2505.16687, 2025.
- [24] Yang R, Mandt S. Lossy image compression with conditional diffusion models[J]. Advances in Neural Information Processing Systems, 2023, 36: 64971-64995.
- [25] Kuang H, Ma Y, Yang W, et al. Consistency guided diffusion model with neural syntax for perceptual image compression[C]//Proceedings of the 32nd ACM International Conference on Multimedia. 2024: 1622-1631.
- [26] Pan Z, Zhou X, Tian H. Extreme generative image compression by learning text embedding from diffusion models[J]. arXiv preprint arXiv:2211.07793, 2022.
- [27] Xu T, Li J, Li B, et al. PICD: Versatile Perceptual Image Compression with Diffusion Rendering[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 28436-28445.
- [28] Murai S, Sun H, Katto J. LMM-driven Semantic Image-Text Coding for Ultra Low-bitrate Learned Image Compression[C]//2024 IEEE International Conference on Visual Communications and Image Processing (VCIP). IEEE, 2024: 1-5.
- [29] Beyler E, Bach F. Optimal Denoising in Score-Based Generative Models: The Role of Data Regularity[J]. arXiv preprint arXiv:2503.12966, 2025.
- [30] Sauer A, Lorenz D, Blattmann A, et al. Adversarial diffusion distillation[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 87-103.
- [31] Sauer A, Boesel F, Dockhorn T, et al. Fast high-resolution image synthesis with latent adversarial diffusion distillation[C]//SIGGRAPH Asia 2024 Conference Papers. 2024: 1-11.
- [32] Li Z, Zhou Y, Wei H, et al. RDEIC: Accelerating Diffusion-Based Extreme Image Compression with Relay Residual Diffusion[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2025.
- [33] Chu H, Wu W, Zang C, et al. Qncd: Quantization noise correction for diffusion models[C]//Proceedings of the 32nd ACM International Conference on Multimedia. 2024: 10995-11003.
- [34] Relic L, Azevedo R, Gross M, et al. Lossy image compression with foundation diffusion models[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 303-319.
- [35] Park C, Lee J C, Ko J H. DiffO: Single-step Diffusion for Image Compression at Ultra-Low Bitrates[J]. arXiv preprint arXiv:2506.16572, 2025.

- [36] Yue Z, Wang J, Loy C C. Resshift: Efficient diffusion model for image super-resolution by residual shifting[J]. *Advances in Neural Information Processing Systems*, 2023, 36: 13294-13307.
- [37] Song J, He J, Yang L, et al. High frequency matters: Uncertainty guided image compression with wavelet diffusion[J]. *arXiv preprint arXiv:2407.12538*, 2024.
- [38] Rippel O, Bourdev L. Real-time adaptive image compression[C]//*International conference on machine learning*. PMLR, 2017: 2922-2930.
- [39] Mari D, Milani S. Enhancing the Rate-Distortion-Perception Flexibility of Learned Image Codecs with Conditional Diffusion Decoders[J]. *arXiv preprint arXiv:2403.02887*, 2024.
- [40] Qi L, Jia Z, Li J, et al. Generative latent coding for ultra-low bitrate image and video compression[J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2025.
- [41] Kim J H, Heo B, Lee J S. Joint global and local hierarchical priors for learned image compression[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022: 5992-6001.
- [42] Mari D, Milani S. Features denoising for learned image coding[C]//*2022 10th European Workshop on Visual Information Processing (EUVIP)*. IEEE, 2022: 1-6.
- [43] Li C, Lu G, Feng D, et al. Misc: Ultra-low bitrate image semantic compression driven by large multimodal model[J]. *IEEE Transactions on Image Processing*, 2024.
- [44] Jia Z, Li J, Li B, et al. Generative latent coding for ultra-low bitrate image compression[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2024: 26088-26098.
- [45] Shindo T, Tatsumi Y, Watanabe T, et al. Guided Diffusion for the Extension of Machine Vision to Human Visual Perception[J]. *arXiv preprint arXiv:2503.17907*, 2025.
- [46] Zhao L, Woo S, Wan Z, et al. epsilon-vae: Denoising as visual decoding[J]. *arXiv preprint arXiv:2410.04081*, 2024.
- [47] Chu H, Wu W, Zang C, et al. Qncd: Quantization noise correction for diffusion models[C]//*Proceedings of the 32nd ACM International Conference on Multimedia*. 2024: 10995-11003.
- [48] Ballé J, Laparra V, Simoncelli E P. End-to-end optimized image compression[J]. *arXiv preprint arXiv:1611.01704*, 2016.
- [49] Brenig J, Timofte R. Higher fidelity perceptual image and video compression with a latent conditioned residual denoising diffusion model[C]//*European Conference on Computer Vision*. Cham: Springer Nature Switzerland, 2024: 194-210.

- [50] Yin T, Gharbi M, Zhang R, et al. One-step diffusion with distribution matching distillation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 6613-6623.
- [51] Liu J, Wang Q, Fan H, et al. Residual denoising diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 2773-2783.